

# Algorithmen und Datenstrukturen Suchen

Matthias Teschner
Graphische Datenverarbeitung
Institut für Informatik
Universität Freiburg

SS 12

#### Lernziele der Vorlesung



- Algorithmen
  - Sortieren, Suchen, Optimieren
- Datenstrukturen
  - Repräsentation von Daten
  - Listen, Stapel, Schlangen, Bäume
- Techniken zum Entwurf von Algorithmen
  - Algorithmenmuster
  - Greedy, Backtracking, Divide-and-Conquer
- Analyse von Algorithmen
  - Korrektheit, Effizienz

#### Überblick



- Einführung
- Sequentielle / lineare Suche
- Binäre Suche
- Exponentielle Suche
- Interpolationssuche
- i-kleinstes Element
- Selbstanordnende Listen

## Suchproblem



- Eingabe: Folge von Zahlen  $< a_1, a_2, \ldots, a_n >$  und Suchelement
- Ausgabe: Suche erfolgreich / nicht erfolgreich.
   Bei Erfolg: Index eines Elements der Folge a, dessen Wert mit dem Suchschlüssel übereinstimmt.
   Definition, wie mit mehreren Lösungen umgegangen wird.
- Eingabemenge als Feld oder verkettete Liste repräsentiert
- Suchverfahren lösen das durch die Eingabe-Ausgabe-Relation beschriebene Suchproblem.

#### Suchen



- grundlegende Operation auf Datenmengen
  - Stichwort in einem Wörterbuch
  - Telefonnummer in einem Verzeichnis
- elementare Suchverfahren
  - Schlüssel sind Zahlen
  - Suche ist erfolgreich oder erfolglos
  - Erfolgreiche Suche liefert Position des gesuchten Element
  - Verfahren basieren auf Vergleichsoperationen
  - Daten sind linear als Feld oder Liste repräsentiert
    - Feld: Zugriff auf Element über Index
    - Liste: Zugriff auf Element über Referenz oder mitgeführten Index
  - Hashverfahren und Baumstrukturen werden nicht berücksichtigt

### Überblick



- Einführung
- Sequentielle / lineare Suche
- Binäre Suche
- Exponentielle Suche
- Interpolationssuche
- i-kleinstes Element
- Selbstanordnende Listen

## Prinzip



 überprüfe sequentiell alle Elemente des Feldes (brute force search)

### Prinzip – Sentinel-Methode



 füge das gesuchte Element an die erste oder letzte Stelle des Feldes ein, spart eine Abfrage pro Durchlauf

```
int seqSearch(int[] a, int k)
                                                  durchsuche a [1..n] nach k
                                                  a[0] gehört nicht zur zu
  a[0] = k;
                                                  durchsuchenden Menge,
   int i = a.length;
                                                  wird mit k initialisiert
                                                  (Stopper-Element)
  do i--; while (a[i]!=k);
                                          Eine Abfrage pro Durchlauf
   if (i!=0)
      return i;
                          Element gefunden
   else
      return -1;
                          Element nicht gefunden
```



- bester Fall: O (1)
- schlechtester Fall: O (n)

• mittlerer Fall: 
$$\frac{1}{n} \sum_{i=1}^{n} i = \frac{1}{n} \frac{n \cdot (n+1)}{2} = \frac{n+1}{2} = O(n)$$

 Feld muss im Gegensatz zu allen weiteren Strategien nicht sortiert sein.

#### Überblick



- Einführung
- Sequentielle / lineare Suche
- Binäre Suche
- Exponentielle Suche
- Interpolationssuche
- i-kleinstes Element
- Selbstanordnende Listen

## Prinzip



- Feld ist sortiert
- gesuchtes Element wird mit mittlerem Element des Feldes verglichen
- bei Ungleichheit wird nur die jeweils linke oder rechte Hälfte des Feldes rekursiv weiter betrachtet
- jeder Vergleich mit dem jeweils mittleren Element teilt den Suchraum in zwei Hälften,
  - bis das Element gefunden wurde
  - bis der verbleibende Suchraum sich nicht weiter unterteilen lässt

## Prinzip



Suche von k auf einem sortierten Feld a (keine Liste!)

|--|

- Vergleich: k==a[m] mit m = (0+n) / 2
- Fall 1: k==a[m] → fertig
- Fall 2: k < a[m] → rekursive Suche von k in a[0..m-1]</p>
- Fall 3: k > a[m] → rekursive Suche von k in a[m+1..n]

### Rekursive Implementierung



```
int binSearch(int[] a, int l, int r, int k) {
  if (1>r) return -1;
  int m = (1+r)/2;
  int e = a[m];
  if (k==e) return m;
  if (k <e) return binSearch(a,1,m-1,k);</pre>
  if (k >e) return binSearch(a,m+1,r,k);
```

#### Iterative Implementierung



```
int binSearch(int[] a, int k) {
  int l=0, r=a.length-1;
  while (1<=r) {
    int m = (1+r)/2;
    int e = a[m];
    if (k==e) return m;
    if (k < e) r = m-1;
    if (k > e) l = m+1;
  return -1;
```

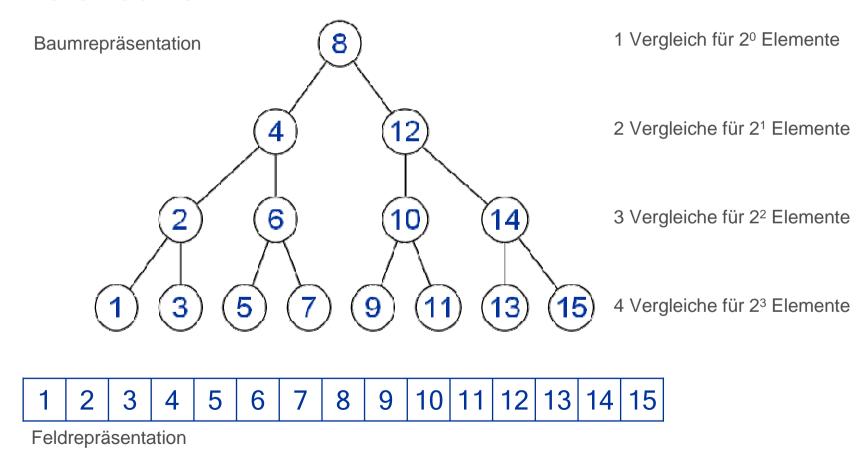
Universität Freiburg - Institut für Informatik - Graphische Datenverarbeitung



- jeder Vergleich reduziert die zu durchsuchende Menge um Faktor 2
- schlechtester Fall: O (log n)
- bester Fall: O (1)



#### mittlere Laufzeit



Universität Freiburg - Institut für Informatik - Graphische Datenverarbeitung



- mittlere Laufzeit
- Zahl der Elemente

$$\sum_{i=0}^{k-1} 2^i = 2^k - 1 = n$$

k – Zahl der Ebenen im Baum

Zahl der Vergleiche

$$\sum_{i=0}^{k-1} 2^{i}(i-1) = \sum_{i=1}^{k} 2^{i-1}i = k \cdot 2^{k} - 2^{k} + 1$$

Vergleiche / Elemente

$$\frac{\log(n+1)\cdot(n+1)-(n+1)+1}{n} \approx \log(n+1) - 1 \in O(\log n)$$

Im Durchschnitt 1 Vergleich weniger als die Maximalzahl möglicher Vergleiche (intuitiv durch Baumrepräsentation klar)

#### Variante



- Fibonacci-Suche
  - Vermeidung der Division bei der Aufteilung der Menge

• 
$$F_0 = F_1 = 1$$
;  $F_n = F_{n-1} + F_{n-2}$   $(n \ge 2)$ 

- Verfahren
  - finde  $F_{n-1}$  und  $F_{n-2}$  mit  $F_{n-1} + F_{n-2} = F_n \ge n$
  - vergleiche k mit a[F<sub>n-2</sub>]
  - Fallunterscheidung und Rekursion wie bei binärer Suche

1 
$$F_{n-2}$$
  $F_{n-1}$   $F_{n-1}$   $F_{n-1}$   $F_{n-1}$ 

mittlerer Aufwand O (log n)

### *Implementierung*



```
int fibSearch(int[] a, int k) {
  int n=a.length-1;
  int fib2=1; fib1=1; fib=fib1+fib2;
                                                     finde Fibonacci-Zahl >=n
  while (fib-1<n) {</pre>
                                                     fib1 und fib2 sind die
    fib2=fib1; fib1=fib; fib=fib1+fib2; }
                                                     Vorgänger von fib
  int offset=0; linker Rand-1
  while (fib>1) {
    int i=min(offset+fib2,n);
    int e=a[i];
    if (k==e) return i;
    if (k<e) {
       fib=fib2; fib1=fib1-fib2; fib2=fib-fib1; }
    if (k>e) {
       offset=i;
       fib=fib1; fib1=fib2; fib2=fib-fib1; }
  return -1
         Universität Freiburg - Institut für Informatik - Graphische Datenverarbeitung
```

#### Überblick



- Einführung
- Sequentielle / lineare Suche
- Binäre Suche
- Exponentielle Suche
- Interpolationssuche
- i-kleinstes Element
- Selbstanordnende Listen

## Prinzip



- n sehr groß gegenüber dem zu suchenden Schlüssel k
- Verfahren

```
j=1; while (k>a[j]) j=2*j;
return binSearch(a,j/2,j,k);
```

- teste a[1], a[2], a[4], .., a[2<sup>j</sup>]
- Aufwand
  - O(log k) Schritte in der while-Schleife
  - O(log j/2) = O(log k) Schritte für binäre Suche

#### Überblick



- Einführung
- Sequentielle / lineare Suche
- Binäre Suche
- Exponentielle Suche
- Interpolationssuche
- i-kleinstes Element
- Selbstanordnende Listen

## Prinzip



- berücksichtige die zu erwartende Position des Schlüssels k im Feld a
- Feld a wird von Position I bis Position r durchsucht
- Annahme: Schlüsselwerte verhalten sich linear zwischen a[l] und a[r]
- Schätzung der Position t durch

$$t=l+(r-l)\frac{k-a[l]}{a[r]-a[l]} \quad \text{Quotient liegt zwischen 0 (für k=a[l]) und 1 (für k=a[r]).}$$
 Damit liegt t zwischen I und r.

 Annahme des linearen Verhaltens stimmt oft nicht mit dem realen Verhalten überein

#### *Implementierung*



```
int interpSearch(int[] a, int k) {
  int l=0, r=a.length-1;
  while (1<=r) {
     int m = 1+(1-r)*(k-a[1])/(a[r]-a[1]);
     int e = a[m];
                                     Wir vergessen natürlich nicht,
                                     a[r]-a[l]==0 irgendwo zu behandeln.
     if (k==e) return m;
     if (k < e) r = m-1;
     if (k > e) l = m+1;
  return -1;
```

Universität Freiburg - Institut für Informatik - Graphische Datenverarbeitung

#### Diskussion



- mittlere Laufzeit: O( log (log n) )
- sehr langsames Wachstum:  $\log (10^9) \approx 30$ ,  $\log (\log (10^9)) \approx 5$
- effizient bei großen Feldern und linearem Verhalten der Schlüssel
- Implementierung im Vergleich zur binären Suche lediglich bei der Berechnung des mittleren Elements aufwendiger

#### Überblick



- Einführung
- Sequentielle / lineare Suche
- Binäre Suche
- Exponentielle Suche
- Interpolationssuche
- i-kleinstes Element
- Selbstanordnende Listen

#### Naiver Ansatz



- finde das i-kleinste Element eines unsortierten Feldes a
- Ansatz

```
• j=0; while (j<i) { min=kleinstesElement(a);
entferne(a,min); j++;} return min;
```

- Aufwand: O(i·n)
- für i=n/2 (Median) ist der Aufwand O(n²)
   → Sortieren und direkter Zugriff auf a [ i ]
   wäre schneller in O(n log n)

## Verwendung eines Heaps



- min-Heap (analog zu max-Heap)
  - binärer Baum, wobei Wert eines Knotens kleiner als die Werte der beiden Nachfolgeknoten ist
  - Wurzel enthält kleinstes Element
  - Aufbau in O(n), Aktualisierung in O(log n)
- i-kleinstes Element mit Hilfe eines Heaps

```
generiereHeap(a);

j=0; while (j<i) { entferne(a,a[0]);

rekonstruiereHeap(a); j++; }

o(log n)

return a[0];</pre>
```

- Aufwand O(n + i · log n)
- mittlerer, schlechtester Fall O (n log n)

#### Teile-und-Herrsche-Ansatz



Aufteilung von a bezüglich Pivotelement p



Divide-Schritt (wie Quick-Sort) O(n)

- Pivot-Element ist an Position m
  - m-l+1 == i → fertig (p ist i-kleinstes Element)
  - m-l+1 > i → rekursiver Divide-Schritt auf a[l .. m-1]
  - m-l+1 < i → rekursiver Divide-Schritt auf a[m+1.. r]</p>

Rekursionstiefe O (log n) bis O(n) Divide-Schritt wird nur auf n, n/2, n/4, ... angewendet

## *Implementierung*



#### Laufzeit Teile-und-Herrsche-Ansatz



- Analog zu Quick-Sort
- bester Fall:
  - Pivotelement teilt Menge in zwei gleichgroße Mengen

    T(n) = T(n/2) + n (Quick-Sort: T(n) = 2 T(n/2) + n) Die Hälfte der Menge kann jeweils verworfen werden.
  - Fall 3 des Master-Theorems:

$$T(n) \in \Theta\left(f(n)\right) \quad \text{falls} \quad f(n) \in \Omega\left(n^{\log_b a + \epsilon}\right) \quad \epsilon > 0$$
 
$$af\left(\frac{n}{b}\right) \leq cf(n) \quad 0 < c < 1$$
 
$$a = 1, \quad b = 2, \quad f(n) = n, \quad \log_b a = \log_2 1 = 0$$
 
$$f(n) \in \Omega\left(n^{\log_2 1 + 1}\right) \quad 1 \cdot \frac{n}{2} \leq c \cdot n \quad c = \frac{1}{2}$$
 
$$T(n) \in \Theta\left(n\right) \approx 2 \cdot n$$



- schlechtester Fall:  $T(n) = T(n-1) + O(n) \rightarrow T(n) \in O(n^2)$
- mittlerer Fall: O(n)
  - spezielle Strategien zum Finden des Pivotelements
  - randomisiert (wähle ein zufälliges Element)
  - Median (wähle in konstanter Zeit mittleres Element aus 3 oder 5 Elementen)

### Überblick



- Einführung
- Sequentielle / lineare Suche
- Binäre Suche
- Exponentielle Suche
- Interpolationssuche
- i-kleinstes Element
- Selbstanordnende Listen

## Prinzip



- ordne häufig gesuchte Elemente an den Anfang des Feldes / der Liste
- verwende sequentielle Suche
- nur vorteilhaft, wenn einige Elemente signifikant häufiger gesucht werden als andere
- werden alle Elemente gleich häufig gesucht, ist das Verfahren schlechter als die sequentielle Suche (sequentielle Suche plus Umordnung der Elemente)

## Strategien



- MF-Regel (move to front)
  - gesuchtes Element wird Kopf der Liste / erstes Element des Feldes
- T-Regel (transpose)
  - gesuchtes Element wird mit unmittelbarem Vorgänger vertauscht
- FC-Regel (frequency count)
  - zähle Suchanfragen pro Element
  - ordne gesuchtes Element so ein, dass die Zählerwerte in der Liste / im Feld absteigend sortiert sind

## Zusammenfassung



- Sequentielle / lineare Suche
  - Feld muss nicht sortiert sein, Laufzeit O(n)
- Binäre Suche
  - Feld muss sortiert sein, Laufzeit O(log n)
  - Fibonacci-Suche vermeidet Division, Laufzeit O(log n)
- Exponentielle Suche
  - sinnvoll, wenn Schlüssel k klein gegenüber Anzahl der Elemente n
  - Feld ist sortiert, Laufzeit O(log k)
- Interpolationssuche
  - Feld ist sortiert, vermutet lineares Verhalten der Schlüsselwerte
  - Laufzeit O (1), wenn die Vermutung stimmt, sonst O (log (log (n)))
- i-kleinstes Element
  - naiv O(n²), min-Heap O (n log n),
  - basierend auf Quick-Sort bei guter Pivotisierung O (n)

#### Nächstes Thema



- Algorithmen / Datenstrukturen
  - Hashverfahren